

AI Agent 기술설명서

항목	기재 내용
팀명 / 부문 / 주제	철철철 / 대학부 ⑤ 경남 지역혁신·공공서비스 AI Agent
작품명	실시간 축제 민원 관제 AI Agent (대상: 진주남강유등축제)
해결 문제	건수 순으로 보면 적게 들어오는 안전 민원(어두운 길·난간·밀림)이 많은 불편 민원(주차·가격)에 묻혀 대응이 늦어진다
대상사용자	축제 운영 담당 주무관·현장 운영요원(관제·조치 화면), 방문객(QR 접수)
Agent Goal	민원을 분류하고 심각도로 순위를 매겨 "지금 조치할 일"과 담당 부서 조치요청서를 만든다
사용 AI/LLM/모델	Claude Opus 5.5(claude-opus-5-5), Claude Code CLI(claude -p) 경유. 심각도 점수는 결정적 함수(severity.ts)가 계산
사용 Tool/API/Data/장비	도구: get_pending-save_classification-lookup_similar(분류), get_window_stats-score_label-raise_alert-save_snapshot(감시), write_request-get_department-collect_quotes-generate_doc-lookup_festival_info(조치), rank_issues-rank_actions-write_briefing-read_agent_results(통합), plan_cycle(계획). Data: 개발용 합성 시드 160 건(실제 리뷰 아님), 축제 정보 수기 시드(TourAPI 미사용), 이태원 공개 112 녹취 11 건(재현 시험용). DB: Supabase Postgres / SQLite, 문서: DOCX
Memory/State/Feedback 구현	- State: 민원·분류·카드·조치 상태·실행 기록(agent_log)을 DB 에 유지 - Memory: 비슷한 과거 민원을 찾아 분류에 참고(lookup_similar), 운영자가 정한 유형을 먼저 씀 - Feedback: 운영자의 조치 상태 변경이 다음 판정에 반영(S-06 미조치 30 분 ×1.2), 운영자가 지정한 '확인 필요' 민원은 다음 분류의 기억
핵심 Workflow (End-to-End)	① 방문객이 QR 화면에서 민원을 쓴다 ② 워커가 개인정보를 가린 뒤 저장하고 접수 원문은 지운다 ③ ①분류 에이전트가 유형·안전 여부를 정한다(신뢰도 0.3 미만은 '확인 필요') ④ ②계획이 이번 주기 단계를 정하고, ②감시가 심각도 함수를 도구로 호출해 등급을 매긴다 ⑤ ③조치가 담당 부서 조치요청서(DOCX)를 만든다 ⑥ ④통합이 관제 카드와 브리핑을 쓴다 ⑦ 운영자가 조치 상태를 바꾸면 다음 주기 판정에 반영된다
핵심기능 3~5 개	1) QR 민원 접수와 개인정보 마스킹 2) LLM 유형 분류와 기억 참고 3) 결정적 심각도 판정(규칙 S-01~S-06, 경계 규칙 B-01~B-04, 계산식 공개) 4) 관제 '지금 조치할 일' 카드와 통합 브리핑 5) 담당 부서 조치요청서 DOCX 자동 생성
기존자산 / 8 일 신규개발분	- 기존자산: 자체 기존 코드 없음. 외부 기존자산: 오픈소스(Node.js, TypeScript, Vite, @supabase/supabase-js, pg, docx, dotenv, qrcode, jsqr, @anthropic-ai/sdk — package.json 기준), AI 모델 Claude(Anthropic), 공개자료(행정안전부 지역축제장 안전관리 매뉴얼·다중운집인파사고 안전관리 가이드라인, 이태원 112 공개 녹취) - 8 일 신규개발: 에이전트 5 종·실행 루프·작업 큐(프레임워크 없이 직접 구현), 심각도 함수, 계획·기억, 관제 카드·문구 검사, 마스킹·인젝션 탐지, 부서 매핑·DOCX, 리플레이·합성 시드, 측정 도구, 웹 앱
대표 테스트 5 건 결과	5/5 통과(정상·보호·빈 입력·API 오류·악의적 입력, 실제 모델) · 분류 정확도 96.9%(31/32, 합성 32 건 참고값) · 프롬프트 공격 26/26 통과 · 공개 112 녹취 재현에서 첫 신고(18:34)에 '즉시' 등급(규칙 분류)
현재 완성도 Level	Level 3 (MVP)
소스코드/저장소(경로)	https://github.com/INJE-NULPOINT/festival-complaint-agent (공개 저장소)
정보출처 및 기타	행정안전부「지역축제장 안전관리 매뉴얼(2024)」·「다중운집인파사고 안전관리 가이드라인」(2024), 「민원 처리에 관한 법률 시행령」 제 19 조(규칙 근거). 개발 보조 Claude Code. 상세는 출처신고서